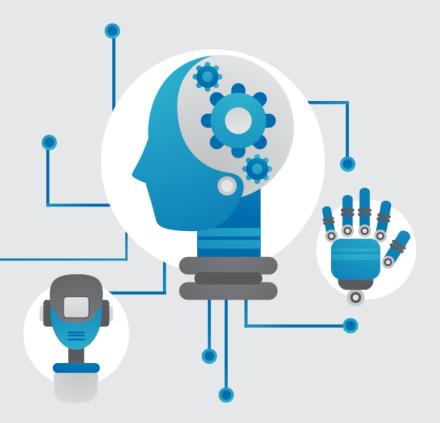




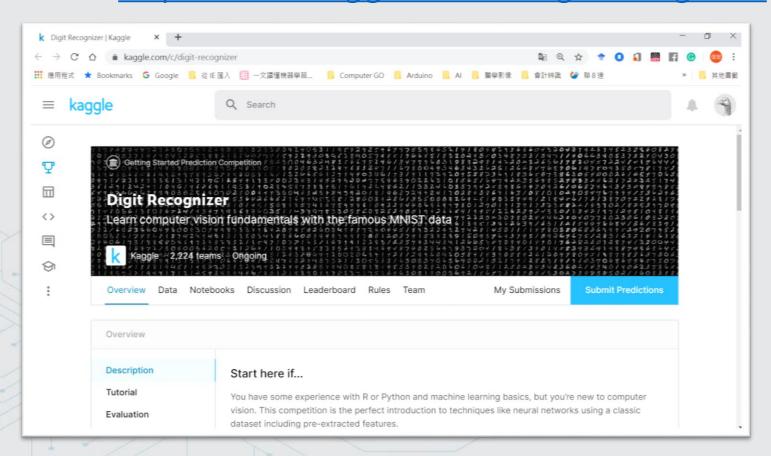
MLP模型建置流程







>網址:https://www.kaggle.com/c/digit-recognizer







- >資料檔案: train.csv, test.csv和sample_submission.csv
 - 訓練資料: train.csv
 - ✓ 共42,000筆資料 (row)
 - ✓ 每個row有785 columns
 - ✓ 第1 column為label,表示該影像的正確答案
 - ✓ 後面784 columns為row major的28x28像素值

1	Α	В	С	D	E	F	G
1	label	pixel0	pixel1	pixel2	pixel3	pixel4	pixel5
2	1	0	0	0	0	0	(
3	0	0	0	0	0	0	(
4	1	0	0	0	0	0	(
5	4	0	0	0	0	0	(
6	0	0	0	0	0	0	(
7	0	0	0	0	0	0	(
8	7	0	0	0	0	0	(
9	3	0	0	0	0	0	(
10	5	0	0	0	0	0	(





- > 資料檔案: train.csv, test.csv和sample_submission.csv
 - 測試資料: test.csv
 - ✓ 共28,000筆資料 (row)
 - ✓ 每個row只有784 columns

	Α	В	С	D	Е	F
1	pixel0	pixel1	pixel2	pixel3	pixel4	pixel5
2	0	0	0	0	0	C
3	0	0	0	0	0	C
4	0	0	0	0	0	C
5	0	0	0	0	0	C
6	0	0	0	0	0	C
7	0	0	0	0	0	C
8	0	0	0	0	0	C
9	0	0	0	0	0	C
10	0	0	0	0	0	C





- >資料檔案: train.csv, test.csv和sample_submission.csv
 - 預測結果: sample_submission.csv
 - ✓ 共28,000筆資料 (row)

	Α	В
1	ImageId	Label
2	1	0
3	2	0
4	3	0
5	4	0
6	5	0
7	6	0
8	7	0
9	8	0
10	9	0



MLP模型建置流程



- 1. 資料前處理
- 2. 決定模型架構
- 3. 編譯與訓練模型
 - 4. 模型評估
 - 5. 調整超參數

7. 進行預測

6. 重複步驟2~5 直到模型效率無法再改進



資料前處理



>從檔案train.csv讀進資料,區分資料x和標記y

```
3#從檔案讀取資料
4 with open('train.csv', 'r') as file:
     csv_lines = file.readlines()
6x = []
7y = []
8 for i in range(1, len(csv_lines)):
     #去掉換行符號並以逗號分割
     row=csv_lines[i].replace('\n', '').split(',')
     #去掉LabeL欄位,並將字串轉為整數
     x.append(list(map(int, row[1:])))
13
    #抓出LabeL欄位,並將字串轉為整數
14
     y.append(list(map(int, row[0])))
16 from keras.utils import to_categorical
17 #one-hot encoding
18 y = to_categorical(y, num_classes=10)
```



資料前處理



>資料正規化

```
20 import numpy as np
21 #轉成np.array,正規化
22 x=np.array(x)/255.0
23 y=np.array(y)
```



決定模型架構



>模型建置

```
27 # 建置模型
28 from keras.models import Sequential
29 from keras.layers import Dense
30 # 宣告Sequential循序模型
31 model = Sequential()
32 # 加入輸入層
33 model.add(Dense(512, activation='relu', input_shape=(784,)))
34 # 加入隱藏層
35 model.add(Dense(512, activation='relu'))
36 # 指定 輸出層模型
37 model.add(Dense(10, activation='softmax'))
```



編譯與訓練模型



> 設定參數,訓練模型

```
40#編譯與訓練模型
41 from keras.optimizers import RMSprop
42# 指定 loss function, optimizier, metrics
43 model.compile(loss='categorical_crossentropy',
               optimizer=RMSprop(),
44
45
               metrics=['acc'])
46# 指定 batch_size, epochs, validation_split後,開始訓練模型
47 history = model.fit(x, y,
                     batch_size=128,
48
                     epochs=20,
                     validation_split=0.2,
50
                     verbose=1)
```



模型評估



>顯示訓練歷程

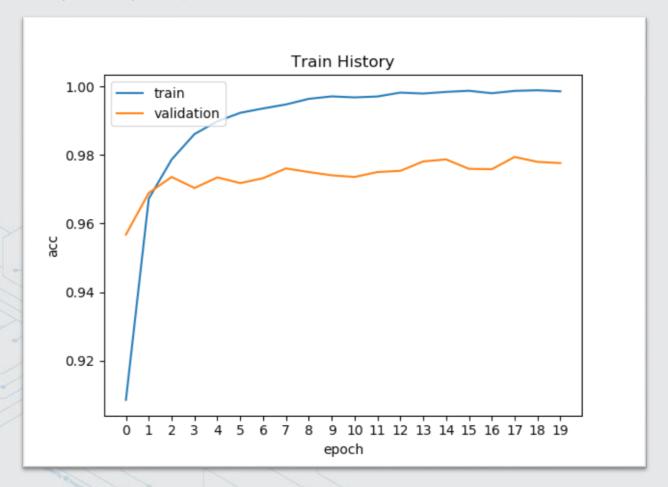
```
53 # 顧示訓練歷程
54 import matplotlib.pyplot as plt
55 def show_train_history(train_history):
56 plt.plot(train_history.history['acc'])
57 plt.plot(train_history.history['val_acc'])
58 plt.xticks([i for i in range(0, len(train_history.history['acc']))])
59 plt.title('Train History')
60 plt.ylabel('acc')
61 plt.xlabel('epoch')
62 plt.legend(['train', 'validation'], loc='upper left')
63 plt.show()
64
65 show_train_history(history)
```



模型評估

機器學習實務

>顯示訓練歷程

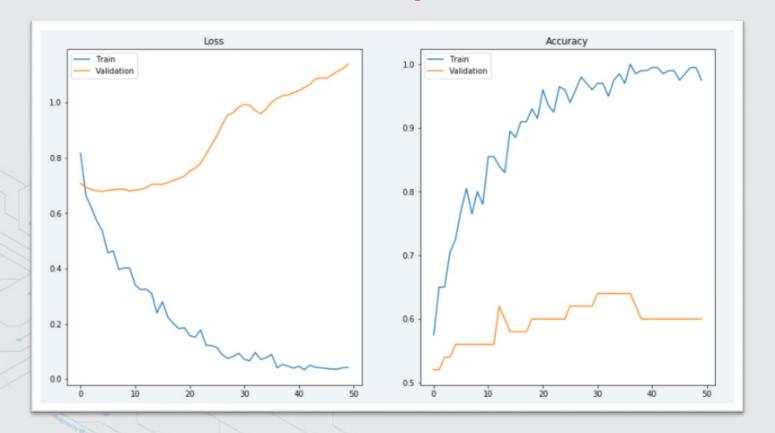




過度學習



> 過度學習(Overfitting)通常是說訓練出來的模型對於 訓練集的預測結果很好,但是對於測試集則是不好。 也就是說模型的通用能力(generalization)不好。





避免過度學習的方法



- >增加訓練集資料數量或資料擴增 (data augmentation)
- >拿掉影響力小的特徵 (feature)

- >資料集進行打亂 (shuffle)
- >減少訓練次數 (epoch)



避免過度學習的方法



>隨機拋棄(Dropout)

在訓練過程中,隨機拿掉一些連結(weight 設為0), 只針對某部分的權重進行調整,更能精確調整權重。

>正則化(Regularization) 在損失函數中添加一個會懲罰大權重值的附加項。

>整合 (Ensembling)

整合多種模型,例如根據多種模型的預測結果用投票法決定最後預測值。

>交叉驗證 (Cross Validation)

將訓練集分割成若干個子樣本集,輪流使用其中一個子樣本集進行驗證,其他則用於訓練,最終整合所有預測結果。



修改模型架構



> 加入 Dropout 和減少訓練次數

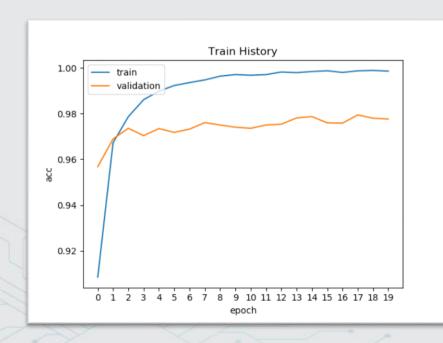
```
27# 模型建置
28 from keras.models import Sequential
29 from keras.layers import Dense, Dropout
30# 宣告Sequential循序模型
31 model = Sequential()
32# 加入輸入層
33 model.add(Dense(512, activation='relu', input_shape=(784,)))
34# 加入Dropout
35 model.add(Dropout(0.5))
36#加入隱藏層
37 model.add(Dense(512, activation='relu'))
38# 加入Dropout
39 model.add(Dropout(0.5))
40# 指定 輸出層模型
41 model.add(Dense(10, activation='softmax'))
```

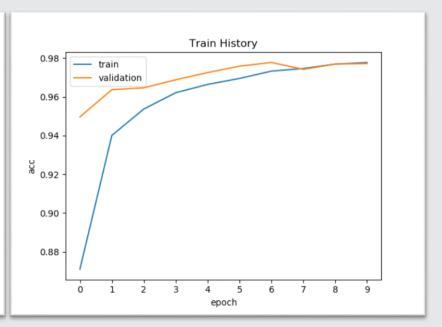


模型再評估



>訓練歷程比較







進行預測



> 將預測結果寫入檔案,上傳Kaggle平台



進行預測



> 將預測結果寫入檔案,上傳Kaggle平台

Overview Data Notebooks Discussion Leaderboard Rules Team		My Submissions	Sub	mit Predictions	
1494 Bryen Moberg	7	0.97414	2	23d	•
1495 shir kozlovsky	9	0.97414	7	2d	
1496 Samiruddin Thunder	•	0.97400	2	1mo	
1497 mmatvienko		0.97400	5	1mo	
1498 Hsuan-Chun Lin	9	0.97400	4	16d	
1499 Hsin-Hung Chou	7	0.97400	1	6m	
Your First Entry ↑ Welcome to the leaderboard!					
1500 Marc Albernhe	3	0.97385	1	2mo	
1501 haroon4412	9	0.97385	4	2mo	